

BAB II

TINJAUAN PUSTAKA

2.1 Tinjauan Pustaka

Penelitian terkait, atau yang sering disebut sebagai tinjauan pustaka, merupakan bagian penting dalam membangun landasan teori sebuah studi. Tinjauan pustaka ini bertujuan untuk menyajikan kajian terhadap penelitian-penelitian yang relevan dalam domain yang sama atau berhubungan dengan penelitian yang sedang dibahas. Dalam konteks penelitian ini, penelitian terkait mencakup beberapa studi yang signifikan dalam Pembangunan Sistem Pengenalan Bahasa Isyarat, khususnya penggunaan *MediaPipe* untuk ekstraksi fitur tangan dan penerapan Algoritma *Convolutional Neural Network* dalam klasifikasi gestur huruf.

Penelitian terkait pertama yang relevan dengan penelitian ini adalah *Gesture Recognition untuk Deteksi Bahasa Isyarat BISINDO Pendekatan MediaPipe dan Random Forest* oleh Kaffah dan Ramdhani. Penelitian ini berangkat dari tantangan dalam mengenali gestur BISINDO menggunakan metode *vision-based*. Tujuannya adalah mendeteksi gestur BISINDO dengan mengombinasikan *landmark* tangan dari *MediaPipe* dan klasifikasi menggunakan *Random Forest*. Hasil penelitian menunjukkan akurasi yang cukup tinggi pada *dataset* gestur sederhana. Penelitian ini berbeda dengan penelitian penulis yang berfokus pada BISINDO *real-time* menggunakan CNN, sementara penelitian terkait berfokus pada BISINDO statis dengan *Random Forest*.

Penelitian terkait kedua yang relevan dengan penelitian ini adalah *Skeleton-based Action Recognition with Convolutional Neural Networks* oleh C. Li, Q. Zhong, D. Xie, dan S. Pu dari Hikvision Research Institute. Penelitian ini berfokus pada pengenalan aksi manusia berbasis data *skeleton* menggunakan CNN tanpa memerlukan fitur buatan (*handcrafted features*). Data *skeleton* berupa koordinat 3D

titik sendi tubuh digunakan langsung sebagai *input* CNN untuk melakukan klasifikasi aksi. Model CNN yang diusulkan memiliki arsitektur sederhana dengan tujuh lapisan dan divalidasi menggunakan *dataset NTU-RGB+D*. Hasilnya menunjukkan bahwa metode CNN yang digunakan mencapai akurasi sebesar 83,2% pada pengujian *cross-subject* dan 89,3% pada *cross-view*, melampaui beberapa pendekatan *state-of-the-art* lain seperti STA-LSTM dan VA-LSTM. Peneliti menyimpulkan bahwa CNN mampu mempelajari pola spasial dan temporal secara efektif dari data *skeleton*, sehingga pendekatan serupa dapat diterapkan pada Sistem Pengenalan Huruf BISINDO yang menggunakan data *landmark* hasil ekstraksi dari *MediaPipe*.

Penelitian terkait ketiga yang relevan berasal dari *A Comparative Analysis of CNN and SVM for Static Sign Language Recognition Using MediaPipe Landmarks* oleh Akbar Kurnia Saleh. Studi ini membandingkan performa CNN dan SVM dalam mengenali alfabet SIBI menggunakan 21 titik *landmark* tangan dari *MediaPipe* sebagai fitur *input*. Penelitian menunjukkan bahwa CNN memberikan hasil terbaik, dengan akurasi pengujian, *F1-score*, *balanced accuracy*, dan ROC AUC yang semuanya mencapai 1.00. Sebaliknya, SVM menghasilkan akurasi 80% dan *F1-score* 0.76, meskipun tetap menunjukkan ROC AUC tinggi sebesar 0.99. Keunggulan utama SVM terletak pada efisiensi komputasi, dengan waktu pelatihan di bawah 0,09 detik, jauh lebih cepat dibandingkan CNN yang membutuhkan sekitar 0,5 detik per *epoch*. Peneliti menegaskan bahwa CNN lebih unggul untuk akurasi tinggi, sementara SVM cocok untuk sistem ringan pada perangkat dengan keterbatasan komputasi.

Penelitian terkait keempat yang relevan dengan penelitian ini adalah *Klasifikasi Abjad SIBI (Sistem Bahasa Isyarat Indonesia) menggunakan MediaPipe dengan metode Deep learning* oleh Muhammad Alfian Pratama, Muhammad Reza Erfit, Nadiya Mujahidatul Farhani, Ignatius Arvantya Hartono, dan Maryamah. Penelitian ini didasari dengan rendahnya pemahaman masyarakat terhadap SIBI yang menghambat komunikasi dengan Tunarungu. Tujuan penelitian ini adalah membangun sistem klasifikasi abjad SIBI menggunakan *MediaPipe* dan *deep learning*. Metode yang digunakan adalah pengumpulan *dataset* citra abjad SIBI,

preprocessing (*resize* dan *augmentasi*), ekstraksi fitur dengan *MediaPipe*, dan pelatihan menggunakan *fully connected layer*. Hasil penelitian menunjukkan akurasi 94,32% pada data latih, 93,52% pada validasi, dan 93,94% pada data uji. Penelitian ini berbeda dengan penelitian penulis yang berfokus pada BISINDO secara *real-time* menggunakan CNN, sementara penelitian terkait berfokus pada Abjad SIBI statis dengan model *fully connected layer*.

Penelitian terkait kelima yang relevan dengan penelitian ini adalah *Pengenalan Bahasa Isyarat Indonesia menggunakan MediaPipe dengan Model Random Forest dan Multinomial Logistic Regression* oleh Imam Suyudi, Sudadio, dan Suherman. Penelitian ini didasari oleh kebutuhan masyarakat akan sistem pengenalan Bahasa Isyarat tanpa perangkat khusus seperti *Leap Motion*. Tujuannya adalah membangun Sistem Pengenalan Abjad SIBI menggunakan kamera RGB biasa dan *MediaPipe*. Metode penelitian menggunakan *dataset* 24 alfabet SIBI, *landmark* tangan dari *MediaPipe*, dan klasifikasi dengan algoritma *Random Forest* serta *Multinomial Logistic Regression*. Hasil menunjukkan bahwa *Random Forest* memberikan akurasi tertinggi hingga 97,19%. Penelitian ini berbeda dengan penelitian penulis yang berfokus pada BISINDO *real-time* dengan CNN, sementara penelitian terkait berfokus pada Abjad SIBI statis dengan algoritma pembelajaran mesin klasik.

Penelitian terkait keenam yang relevan dengan penelitian ini adalah *Klasifikasi alfabet bahasa isyarat Indonesia (BISINDO) dengan Algoritma Convolutional Neural Network* oleh Intan Patresia Tambun. Penelitian ini dilatarbelakangi oleh kesenjangan komunikasi antara Tunarungu dan masyarakat umum. Tujuannya adalah membangun model klasifikasi Abjad BISINDO menggunakan CNN. Metode penelitian melibatkan *dataset* dengan 3.095 gambar, *preprocessing* berupa *augmentasi* dan *normalisasi*, serta arsitektur CNN dengan *Conv2D*, *MaxPooling*, *Dense*, dan *Dropout*. Hasil penelitian menunjukkan akurasi sekitar 90%. Penelitian ini berbeda dengan penelitian penulis yang berfokus pada

BISINDO *real-time* menggunakan CNN dengan dukungan *MediaPipe*, sementara penelitian terkait hanya membahas klasifikasi Abjad BISINDO berbasis citra statis.

Penelitian terkait ketujuh yang relevan dengan penelitian ini adalah *Pengenalan Isyarat Tangan dan Pengaruh Lingkungan pada Ekstraksi Fitur* oleh Andika Mulyawan Dwi Prapmanto dan Setia Budi. Penelitian ini dilatarbelakangi oleh tantangan pengaruh pencahayaan dan latar belakang pada akurasi pengenalan Isyarat tangan. Tujuannya adalah menganalisis pengaruh kondisi lingkungan pada klasifikasi Isyarat BISINDO. Metode penelitian menggunakan *preprocessing Canny edge detection* dan klasifikasi dengan *Support Vector Machine*. Hasil penelitian menunjukkan bahwa kondisi latar hitam dengan cahaya depan menghasilkan akurasi tertinggi yaitu 98,23%. Penelitian ini berbeda dengan penelitian penulis yang berfokus pada BISINDO *real-time* menggunakan CNN dan *MediaPipe*, sementara penelitian terkait menekankan analisis faktor lingkungan dengan SVM.

Penelitian terkait kedelapan yang relevan dengan penelitian ini adalah *SLRNet: A Real-time LSTM-Based Sign Language Recognition System* oleh Sharvari Kamble. Penelitian ini berangkat dari kurangnya sistem *real-time* pengenalan ASL yang akurat tanpa perangkat khusus. Tujuannya adalah membangun sistem *real-time* ASL dengan *MediaPipe Holistic* dan LSTM. Metode penelitian mencakup ekstraksi *landmark* wajah, tangan, dan tubuh dengan *MediaPipe*, kemudian klasifikasi dengan LSTM. Hasil penelitian menunjukkan akurasi validasi 86,7%. Penelitian ini berbeda dengan penelitian penulis yang berfokus pada BISINDO *real-time* menggunakan CNN, sementara penelitian terkait berfokus pada ASL dengan LSTM.

2.2 Bahasa Isyarat

Bahasa Isyarat merupakan salah satu bentuk komunikasi non-verbal, yaitu cara berkomunikasi tanpa menggunakan kata-kata lisan. Bentuk komunikasi ini diwujudkan melalui gerakan tubuh, khususnya tangan, ekspresi wajah, hingga gerak bibir, yang dapat diterapkan secara sadar maupun tidak sadar untuk menyampaikan maksud tertentu. Dengan kata lain, Bahasa Isyarat menjadi sarana penting bagi

individu, khususnya komunitas Tunarungu dan Tunawicara, untuk menyalurkan pesan, emosi, maupun informasi tanpa bergantung pada suara (Najib, 2025). Bahasa Isyarat berkembang dengan menyesuaikan tempat ia digunakan seperti lingkungan dan budaya setempat. Di Indonesia ada dua Bahasa Isyarat yang umum digunakan yakni BISINDO dan SIBI.

2.2.1 SIBI

Sistem Isyarat Bahasa Indonesia (SIBI) adalah sistem Bahasa Isyarat yang dirancang pemerintah untuk membantu penyandang Tunarungu dalam pendidikan formal. SIBI dikategorikan sebagai *manually coded language*, yaitu sistem yang mengisyaratkan setiap kata sesuai tata bahasa Bahasa Indonesia, sehingga lebih menyerupai transliterasi dari bahasa lisan ke bentuk visual (Kuswardhana et al., 2021). Adapun gerakan untuk Abjad SIBI dapat dilihat pada Gambar 2.1.



Gambar 2.1 Abjad dalam SIBI


Sumber: Safira, 2022

Penggunaan SIBI banyak diterapkan di Sekolah Luar Biasa (SLB) maupun institusi pendidikan formal karena dianggap memudahkan siswa Tunarungu dalam memahami struktur bahasa Indonesia tulis (Rudiyanto et al., 2024). Namun, SIBI sering dianggap kurang natural digunakan dalam percakapan sehari-hari komunitas Tunarungu, karena tata bahasanya tidak mengikuti pola alami komunikasi visual mereka .

Dengan demikian, SIBI lebih digunakan sebagai alat bantu dalam proses belajar-mengajar, terutama dalam mendukung literasi bahasa Indonesia pada anak-anak Tunarungu, tetapi kurang populer dalam komunitas Tunarungu di luar lingkup pendidikan.

2.2.2 BISINDO

Bahasa Isyarat Indonesia (BISINDO) ialah Bahasa Isyarat alami yang berkembang di komunitas Tunarungu dan digunakan secara luas dalam interaksi sehari-hari. BISINDO dianggap lebih mudah dipahami dan lebih sesuai dengan pola komunikasi visual komunitas Tunarungu dibandingkan dengan SIBI, yang mengikuti tata bahasa Indonesia tulis dan lebih banyak digunakan dalam pendidikan formal (Nugraheni et al., 2023). Adapun gerakan untuk Abjad BISINDO dapat dilihat pada Gambar 2.2.



Gambar 2.2 Abjad dalam BISINDO

Sumber: Safira, 2022

BISINDO merupakan Bahasa Isyarat alami yang berkembang dalam komunitas Tunarungu di Indonesia. Bahasa ini muncul dari interaksi sehari-hari antarpemakai dan diakui sebagai bagian dari identitas budaya mereka (Putri et al., 2022). BISINDO dipelajari secara alami seperti bahasa daerah, dengan variasi di setiap wilayah, sehingga lebih sesuai dengan pola komunikasi visual alami komunitas Tunarungu dibandingkan sistem Bahasa Isyarat buatan (Gumelar et al., 2018).

2.3 Machine Learning

Machine Learning (ML) merupakan cabang dari kecerdasan buatan yang berfokus pada kemampuan sistem untuk belajar dari data dan kemudian melakukan klasifikasi atau pengambilan keputusan tanpa diprogram secara eksplisit. Prinsip utama ML adalah bahwa pola dan pengetahuan dapat diekstraksi dari data menggunakan metode matematis maupun statistik. Dengan demikian, ML mampu

menyelesaikan berbagai masalah dunia nyata dengan memanfaatkan data historis (Sarker, 2021).

Berbeda dengan pemrograman tradisional yang mengandalkan seperangkat aturan yang ditentukan manusia, ML berorientasi pada pengalaman yang diperoleh dari data historis. Semakin banyak data yang dianalisis, semakin baik pula kinerja sistem dalam menyelesaikan tugas tertentu, yang dalam literatur dikenal sebagai prinsip *learning from experience* (Sarker, 2021). *Machine learning* dapat dikategorikan dalam tiga jenis utama: *supervised learning*, *unsupervised learning*, dan *reinforcement learning*.

2.3.1 Supervised Learning

Supervised learning merupakan pendekatan ML yang melibatkan data berlabel, yaitu data yang sudah memiliki *input* dan *output* yang benar. Tujuan utama metode ini adalah mempelajari suatu fungsi yang dapat memetakan data masukan ke hasil keluaran dengan akurasi tinggi. Algoritma seperti regresi linear, SVM, dan *neural networks* banyak digunakan dalam paradigma ini (Sarker, 2021).

Ciri khas *supervised learning* adalah adanya tahap pelatihan (*training*) dengan *dataset* berlabel dan pengujian (*testing*) menggunakan data baru untuk mengevaluasi kemampuan generalisasi model (Ono & Goto, 2022). Melalui penerapan strategi tersebut, model tidak sekadar mampu mempelajari pola dari data yang sudah diketahui, tetapi juga diuji kemampuannya dalam klasifikasi yang akurat pada data asing.

2.3.2 Unsupervised learning

Tidak seperti *supervised learning*, *unsupervised learning* tidak butuh data berlabel. Model berusaha menemukan struktur atau pola tersembunyi dalam data tanpa adanya informasi keluaran yang jelas. Metode populer dalam pendekatan ini antara lain *clustering* (seperti *k-means* dan *hierarchical clustering*) serta

dimensionality reduction (misalnya *principal component analysis* atau PCA) (Shalev-Shwartz & Ben-David, 2013).

Paradigma ini sangat bermanfaat ketika jumlah data besar, tetapi proses pelabelan sulit atau mahal untuk dilakukan. Contoh aplikasinya adalah segmentasi pelanggan dalam dunia pemasaran, di mana perusahaan dapat mengelompokkan konsumen berdasarkan perilaku belanja tanpa harus mengetahui label kategorinya terlebih dahulu. Selain itu, *unsupervised learning* juga digunakan dalam deteksi anomali, seperti menemukan pola transaksi mencurigakan dalam sistem perbankan (Sarker, 2021).

2.3.3 Reinforcement Learning

Reinforcement learning (RL) merupakan Skema pembelajaran dinamis yang menitikberatkan pada hubungan timbal balik antara agen pengambil keputusan dengan lingkungan eksternalnya. Agen menerima umpan balik berupa *reward* atau *penalty* setelah melakukan suatu tindakan, dan secara bertahap menyesuaikan strateginya agar dapat memaksimalkan total *reward* kumulatif (Kaelbling et al., 1996). Proses ini menjadikan RL berbeda dengan *supervised* maupun *unsupervised learning* karena pembelajaran terjadi melalui pengalaman langsung, bukan melalui pasangan data berlabel maupun pencarian pola tersembunyi.

Salah satu konsep penting dalam RL adalah dilema eksplorasi dan eksploitasi. Eksplorasi berarti agen mencoba berbagai tindakan baru untuk menemukan kemungkinan strategi yang lebih baik, sedangkan eksploitasi berarti memilih tindakan yang sudah terbukti memberikan *reward* tinggi berdasarkan pengalaman sebelumnya. Keseimbangan antara keduanya sangat penting agar agen tidak hanya terpaku pada strategi yang sudah dikenal, tetapi juga mampu menemukan solusi optimal dalam jangka panjang (Sarker, 2021).

2.4 Deep learning


Deep learning adalah bagian dari *machine learning* yang mengimplementasikan struktur jaringan saraf tiruan multilapis demi mendalami pola data yang kompleks untuk mempelajari representasi data secara hierarkis. Konsep utamanya adalah bahwa setiap lapisan dalam jaringan mampu mengekstraksi fitur dari data mentah, dari fitur sederhana sampai fitur yang lebih kompleks, sehingga menghasilkan performa lebih tinggi dibandingkan dengan algoritma *machine learning* tradisional (LeCun et al., 2015).

Deep learning berkembang pesat berkat ketersediaan data dalam jumlah besar dan meningkatnya kapasitas komputasi, terutama penggunaan *graphics processing unit* (GPU) untuk pelatihan model berskala besar (Deng & Yu, 2013).

2.5 Convolutional Neural Networks

Convolutional Neural Networks merupakan Susunan hierarki dari model jaringan saraf buatan yang banyak digunakan untuk mengolah data berbentuk grid, seperti citra dan video. Prinsip kerja CNN dirancang dengan mengadopsi mekanisme korteks visual pada manusia melalui lapisan konvolusi yang mampu mengekstraksi fitur lokal secara otomatis, sehingga sangat efektif dalam mengenali pola visual (LeCun et al., 2015). Pada penelitian ini, arsitektur CNN diadaptasi untuk memproses data koordinat *landmark* tangan yang direpresentasikan dalam bentuk matriks 2D (*pseudo-image*), sehingga meskipun *input* bukan citra asli, model tetap dapat belajar pola spasial antar-titik. Arsitektur ini dirancang secara mandiri dengan mengacu pada prinsip-prinsip umum *Convolutional Neural Network* (CNN) serta hasil eksplorasi literatur yang relevan. Pendekatan serupa juga diterapkan dalam penelitian oleh Saleh (2025), yang menggunakan kombinasi dua *convolutional layer* yang diikuti oleh *batch normalization*, fungsi aktivasi ReLU, dan *max pooling*, serta dua *fully connected layer* pada arsitektur CNN untuk mengklasifikasikan gestur Bahasa Isyarat berbasis *landmark* tangan *MediaPipe* dengan fokus pada ekstraksi pola spasial dan peningkatan akurasi klasifikasi. Pendekatan ini sejalan dengan

konsep yang digunakan oleh Li et al. (2017), yang membentuk *skeleton* menjadi 2D *array* agar CNN dapat mempelajari korelasi lokal antar sendi. Dengan cara ini, CNN mampu mengekstraksi korelasi posisi antar-*joint* dan menghasilkan fitur yang lebih representatif untuk proses klasifikasi.



Gambar 2.3 Proses *Convolutional Neural Network*

Sumber: Zaniolo & Marques, 2020

CNN terdiri atas beberapa *layer* utama, yaitu *convolutional layer*, *pooling layer*, dan *fully connected layer*, yang secara bertahap mengubah data *input* menjadi representasi fitur yang lebih abstrak.

2.5.1 Convolutional Layer

Lapisan konvolusi adalah inti CNN yang digunakan untuk mengekstraksi fitur lokal dari data *input*. *Filter* (kernel) yang berukuran kecil digeser di atas citra untuk memperoleh *feature map* yang mampu mengenali fitur dasar seperti tepi serta tekstur. Konsep *weight sharing* membuat CNN lebih efisien karena parameter yang dipelajari lebih sedikit dibanding jaringan tradisional (Albawi et al., 2017).

Secara matematis, konvolusi merepresentasikan perkalian matriks antara filter dengan bagian tertentu, menghasilkan *feature map* yang menyoroti keberadaan pola tersebut. Semakin dalam lapisan konvolusi, semakin kompleks pola yang dapat

dikenali, dari fitur sederhana hingga representasi objek yang lebih abstrak (Goodfellow et al., 2016).

2.5.2 Pooling Layer

Pooling layer berfungsi mereduksi dimensi data sambil mempertahankan fitur penting. Teknik populer adalah *max pooling* dan *average pooling*. *Max pooling* menjaga fitur paling dominan, sedangkan *average pooling* meratakan distribusi fitur. Fungsi utama *pooling* adalah memberikan *translation invariance* dan mengurangi kompleksitas komputasi (Gu et al., 2018).

Pooling menyediakan *translational invariance*, yaitu kemampuan model mengenali fitur meskipun terjadi pergeseran kecil, serta memperluas *receptive field* secara bertahap seiring bertambahnya lapisan (Boureau et al., 2010; Scherer et al., 2010). Meski begitu, metode seperti *max pooling* terkadang membuang informasi penting di area lain selain nilai maksimum; oleh karena itu, teknik lanjutan seperti *Spatial Pyramid Pooling* (SPP), *adaptive pooling*, dan *soft pooling* telah dikembangkan untuk menjaga informasi spasial lebih baik (He et al., 2014).

2.5.3 Fully Connected Layer

Setelah fitur diekstraksi, CNN menggunakan *fully connected layer* (FC) sebagai tahap klasifikasi. FC *layer* menerima *flattened feature map* dan memetakan representasi fitur ke kelas target menggunakan fungsi aktivasi seperti *softmax*. Peran utamanya mirip dengan *multilayer perceptron* yang menghubungkan informasi spasial menjadi *klasifikasi* akhir (Shrestha & Mahmood, 2019).

Selain itu, *fully connected layer* berfungsi mengintegrasikan informasi dari berbagai fitur lokal sehingga menghasilkan representasi global yang komprehensif. Namun, karena jumlah parameter yang besar, lapisan ini rentan terhadap *overfitting*, terutama ketika *dataset* terbatas. Untuk mengatasi hal tersebut, teknik regularisasi seperti *dropout* sering diterapkan pada FC *layer* guna mengurangi korelasi antar *neuron* dan meningkatkan kemampuan generalisasi model (Srivastava et al., 2014).


2.6 MediaPipe

MediaPipe merupakan *framework open-source* yang dirilis oleh Google untuk membangun pipeline *machine learning* berbasis multimedia secara *real-time*. *Framework* ini dirancang agar dapat digunakan secara lintas *platform*, mencakup *desktop*, web, perangkat *mobile*, hingga *edge devices*. *MediaPipe* memanfaatkan arsitektur berbasis graf, di mana data mengalir melalui node-node modular yang disebut *calculators*. Setiap *calculator* bertanggung jawab terhadap fungsi tertentu, seperti pra-pemrosesan data, inferensi model, hingga visualisasi keluaran. Pendekatan ini memungkinkan fleksibilitas tinggi serta kemudahan dalam pengembangan *pipeline* kompleks tanpa harus menulis ulang keseluruhan kode (Lugaresi et al., 2019).

Kelebihan utama *MediaPipe* terdapat pada efisiensi dan kinerjanya dalam pemrosesan data *real-time*. *Framework* ini dioptimalkan agar dapat menjalankan model *deep learning* secara langsung di perangkat dengan latensi rendah, sehingga sangat sesuai untuk aplikasi yang membutuhkan respon cepat seperti pelacakan wajah, estimasi pose, deteksi objek, dan pengenalan gestur tangan. Mekanisme modularitas juga memungkinkan pengembang untuk mengganti atau menambahkan *calculator* baru sesuai kebutuhan tanpa mengubah keseluruhan *pipeline* (Zhang et al., 2020).

Dalam implementasinya, *MediaPipe* telah digunakan secara luas pada berbagai aplikasi *computer vision*. Salah satu contoh populer adalah *MediaPipe Hands*, yang terdiri dari dua model utama: *palm detector* untuk mendeteksi lokasi tangan, dan *landmark predictor* untuk memetakan 21 titik koordinat pada tangan secara *real-time*. *Palm detector* bekerja dengan mendeteksi telapak tangan terlebih dahulu, hal ini dikarenakan telapak tangan merupakan objek yang lebih mudah untuk dideteksi. Setelah telapak tangan terdeteksi, barulah *MediaPipe* dapat menentukan lokasi tangan untuk seterusnya memetakan titik koordinat tangan (Alvin et al., 2021). Desain *pipeline* ini tidak hanya meningkatkan akurasi tetapi juga menghemat komputasi dengan cara menjalankan detektor telapak hanya ketika diperlukan.

Konsep serupa juga diterapkan pada *MediaPipe Pose* dan *MediaPipe Face Mesh*, yang menunjukkan kemampuan *framework* ini untuk mengintegrasikan model *machine learning* dengan *pipeline* pemrosesan multimedia secara efisien (Lugaresi et al., 2019; Zhang et al., 2020).



Gambar 2.4 Titik Koordinat pada Tangan

Sumber: Arsheldy Alvin et al., 2021

Meskipun *MediaPipe Hands* menunjukkan efisiensi yang tinggi dalam memetakan koordinat tangan pada kondisi normal, performa arsitektur ini sangat bergantung pada keutuhan visual dan struktur anatomi tangan yang ideal. Untuk menguji batasan tersebut, Pu et al. (2023) melakukan evaluasi ketahanan (*robustness evaluation*) pada beberapa model *Hand Pose Estimation* (HPE), yaitu *MediaPipe Hands*, *OpenPose*, *BodyHands*, dan *NSRM Hand* menggunakan pendekatan *Metamorphic Testing*. Penelitian tersebut menguji performa model pada berbagai kondisi yang umum ditemui di dunia nyata, seperti oklusi (*occlusion*), variasi pencahayaan (*illumination variations*), dan *motion blur*. Hasil penelitian menunjukkan bahwa ketiga kondisi tersebut dapat menurunkan akurasi estimasi pose tangan serta mengurangi jumlah tangan yang berhasil dideteksi oleh model. Selain itu, penelitian ini menemukan bahwa tidak semua *landmark* tangan memiliki tingkat kepentingan yang sama dalam proses estimasi pose. Ketika satu jari tertutup sepenuhnya, performa model mengalami penurunan yang signifikan karena

perubahan bentuk tangan yang teramati oleh sistem. Temuan ini menunjukkan bahwa model HPE, termasuk *MediaPipe Hands*, masih memiliki keterbatasan dan kerentanan error berupa miscalculasi koordinat ketika harus menangani kondisi tangan yang tidak sepenuhnya terlihat, mengalami amputasi, atau mengalami perubahan struktur fisik yang signifikan.

Dalam konteks penelitian ini, *MediaPipe Hands* digunakan sebagai komponen utama untuk mendeteksi dan mengekstraksi koordinat *landmark* tangan pada saat pengguna melakukan gestur Huruf BISINDO di depan kamera. Titik-titik koordinat (x, y, z) dari setiap jari dan telapak tangan hasil deteksi *MediaPipe Hands* disimpan dalam format CSV dan menjadi *dataset* utama untuk pelatihan model CNN. Selain itu, *MediaPipe* juga digunakan pada tahap implementasi aplikasi *real-time*, di mana hasil deteksi *landmark* dikirim ke model CNN yang telah dilatih untuk mengenali Huruf BISINDO secara langsung melalui kamera.

2.7 Real-time Processing

Real-time processing merupakan kemampuan sistem dalam memproses data secara langsung pada saat data tersebut diterima, sehingga hasil keluaran dapat segera digunakan untuk pengambilan keputusan atau interaksi. Sistem yang memiliki ketepatan tidak hanya ditentukan oleh kebenaran logis hasil komputasinya, tetapi juga oleh waktu saat hasil tersebut dihasilkan. Dengan demikian, sistem yang harus merespons masukan eksternal dalam jangka waktu terbatas dan terdefinisi dapat dikategorikan sebagai *real-time system* (Malgaonkar, 2015).

Keunggulan dari *real-time processing* adalah kemampuannya meningkatkan pengalaman interaktif pengguna serta mendukung implementasi sistem cerdas yang adaptif terhadap perubahan lingkungan. Namun, tantangan yang muncul terletak pada *trade-off* antara kecepatan pemrosesan dan akurasi *klasifikasi*. Penelitian menunjukkan bahwa pendekatan komputasi efisien seperti *model compression*, *quantization*, dan penggunaan *framework* ringan (misalnya *TensorRT*, *MediaPipe*,

atau *TFLite*) dapat meningkatkan performa *real-time* tanpa mengorbankan akurasi secara signifikan (Liang et al., 2021).

2.8 Augmentasi Data

Augmentasi data adalah teknik yang digunakan untuk memperluas dan memperkaya *dataset* dengan cara melakukan transformasi pada data yang sudah ada, seperti rotasi, *Flipping*, *Cropping*, *Scaling*, *Shifting*, hingga penambahan *noise*. Tujuan utama augmentasi data adalah meningkatkan keberagaman data pelatihan sehingga model lebih tahan terhadap variasi *input* dan terhindar dari masalah *overfitting*. Dalam bidang pengolahan citra, augmentasi terbukti efektif dalam meningkatkan akurasi model klasifikasi, deteksi objek, maupun segmentasi gambar (Shorten & Khoshgoftaar, 2019).

Dalam konteks pengolahan data koordinat hasil ekstraksi *landmark*—seperti pada Sistem Pengenalan Bahasa Isyarat berbasis *MediaPipe*—augmentasi spasial digunakan untuk meningkatkan variasi data tanpa mengubah pola gerakan dan hubungan antar-titik. Teknik ini bekerja secara langsung pada nilai koordinat (x, y, z) dari setiap *landmark* sehingga variasi yang dihasilkan tetap konsisten secara spasial. Augmentasi spasial umumnya mencakup tiga transformasi geometris utama, yaitu *Translation*, *Rotation*, dan *Scaling*, yang diterapkan secara hati-hati untuk menjaga integritas struktur koordinat (Xin et al., 2024).

2.9 Tools

2.9.1 Python

Python merupakan bahasa pemrograman yang diadopsi secara luas dalam ilmiah, pembelajaran mesin, dan *data science* karena sintaksnya yang bersih, fleksibel, dan didukung oleh ekosistem pustaka seperti *NumPy*, *SciPy*, dan *Pandas*. Studi terbaru menyatakan bahwa Python tetap menjadi bahasa pilihan utama untuk komputasi ilmiah dan pembelajaran mesin karena kemampuannya dalam

meningkatkan produktivitas dan performa melalui API tingkat tinggi dan integrasi dengan pustaka numerik yang dioptimalkan (Raschka et al., 2020).

2.9.2 TensorFlow

TensorFlow merupakan pustaka *open-source* yang besutan Google Brain Team. Dirancang untuk mendukung *machine learning* dan *deep learning* pada skala besar, *TensorFlow* memanfaatkan representasi berbasis *dataflow graphs* agar dapat berjalan efisien di perangkat yang heterogen, mulai dari CPU hingga perangkat *mobile* atau *edge* (Abadi et al., 2016).

2.9.3 OpenCV

Diluncurkan pertama kali oleh Intel pada tahun 1999, *OpenCV* (*Open Source Computer Vision Library*) hadir sebagai *platform* berbasis *open-source* yang dikhususkan untuk mendukung riset di bidang *computer vision* dan *machine learning*. Ditulis terutama dalam bahasa C++ dan kini tersedia untuk Python, Java, dan JavaScript, *OpenCV* menyediakan berbagai fungsi efisien untuk pemrosesan citra dan video secara *real-time* (Bradski & Kaehler, 2008). Pustaka ini mendukung beragam tugas visi komputer seperti pengolahan citra digital, analisis gerakan, deteksi objek, dan pengenalan wajah, serta dilengkapi dengan fitur dasar seperti konversi warna, *filtering*, dan transformasi geometrik. Kinerja tinggi dan kemudahan integrasinya menjadikan *OpenCV* salah satu pustaka paling populer dalam pengembangan aplikasi berbasis visi komputer (OpenCV Team, n.d.).

Dalam penelitian ini, *OpenCV* berperan sebagai penghubung antara kamera, sistem deteksi tangan, dan antarmuka pengguna. Pustaka ini digunakan untuk menangkap video secara *real-time* sebagai *input* bagi *MediaPipe Hands*, melakukan pra-pemrosesan seperti *flip* horizontal dan konversi warna BGR ke RGB, serta menampilkan hasil deteksi *landmark* tangan selama proses perekaman *dataset* dan pengujian Sistem Pengenalan Huruf BISINDO.

2.9.4 Flask

Flask merupakan sebuah *micro web framework* berbasis Python yang dirancang untuk menyederhanakan serta mempercepat tahapan pengembangan sistem berbasis web. *Flask* menyediakan struktur dasar untuk membangun aplikasi berbasis *website*, seperti *routing*, pemrosesan *request* dan *response*, serta pembuatan layanan berbasis API tanpa membutuhkan konfigurasi yang kompleks (Guardia, 2016).

Selain itu, *Flask* banyak digunakan dalam pengembangan aplikasi berbasis layanan (*web service*) karena kemampuannya dalam mendukung arsitektur RESTful serta komunikasi antar sistem secara efisien (Azhari, 2022). Dengan keunggulan tersebut, *Flask* menjadi salah satu *framework* yang populer untuk membangun aplikasi web maupun penghubung model komputasi dan antar muka pengguna.


2.9.5 Google Colab

Google Colab adalah layanan berbasis *cloud* yang disediakan oleh Google untuk mempermudah pembangunan, pengembangan dan pelatihan model *machine learning*. Dengan Colab, eksekusi dan penulisan skrip Python dapat dilakukan langsung pada web tanpa konfigurasi tambahan. Dalam mendukung aktivitas analisis data, Google Colab menyediakan ekosistem pustaka bawaan yang kaya, termasuk Pandas untuk manipulasi data serta Matplotlib dan Plotly untuk kebutuhan grafik. Kemudahan ini membebaskan pengguna dari keharusan melakukan penyetelan aplikasi pada komputer lokal saat menyusun visualisasi data (Bisong, 2019).

2.10 Cross Industry Standard Process for Data Mining

CRISP-DM (*Cross Industry Standard Process for Data Mining*) merupakan metodologi standar terbuka yang digunakan secara luas dalam industri dan penelitian untuk merancang, mengelola, serta melaksanakan proyek *data mining* dan *data science* (Chapman et al., 2000). Kerangka ini dikembangkan dengan tujuan

memformalkan dan menggeneralisasi langkah-langkah dalam proyek analitik, sehingga dapat diterapkan lintas domain dan teknologi secara efisien.



Gambar 2.5 Diagram Proses CRISP-DM

Sumber: Wikipedia contributors, 2026

Kerangka CRISP-DM terdiri atas enam fase utama:

1. *Business Understanding*

Menetapkan konteks dan sasaran bisnis dari proyek, termasuk menentukan tujuan strategis dan keberhasilan yang diharapkan.

2. *Data Understanding*

Mengumpulkan, mengeksplorasi, dan mengevaluasi kualitas data untuk memahami struktur dan karakteristik data.

3. *Data Preparation*

Melakukan pembersihan, transformasi, dan seleksi data untuk mempersiapkan informasi yang relevan bagi model.

4. *Modeling*

Menentukan, membangun, dan menyetel model statistik atau *machine learning*.

5. *Evaluation*

Mengukur performa model dan memastikan bahwa hasilnya sesuai dengan sasaran bisnis.

6. *Deployment*

Menerapkan model dalam lingkungan produksi, termasuk *monitoring* dan pemeliharaan hasilnya.

Fase-fase ini membentuk lingkaran proses yang iteratif dan tidak linier, memungkinkan penyesuaian berkelanjutan selama proyek berjalan (Schröer et al., 2021).

Studi terbaru menunjukkan bahwa CRISP-DM masih menjadi metodologi *de facto* untuk proyek *data mining* dan *data science* meskipun lebih dari dua dekade telah berlalu sejak pengembangannya (Martinez-Plumed et al., 2021). CRISP-DM dihargai karena fleksibilitasnya—dapat diadaptasi dengan prinsip *Agile* maupun dikembangkan untuk kebutuhan ML *modern*, seperti *framework* CRISP-ML(Q) yang menambahkan aspek *quality assurance* dalam *lifecycle* ML (Studer et al., 2021).

2.11 Evaluasi dan Pengujian

Evaluasi dan pengujian merupakan tahap penting dalam pengembangan model pembelajaran mesin untuk menilai sejauh mana performa model ketika mengeksekusi sekumpulan sampel uji yang berada di luar *dataset* pelatihan. Proses evaluasi biasanya menggunakan metrik evaluasi kuantitatif agar kinerja model dapat diukur secara objektif dan dapat dibandingkan dengan metode lain. Metrik yang paling umum digunakan dalam klasifikasi adalah akurasi, presisi, *recall*, *F1-score*, dan *confusion matrix* di mana tiap metrik menghasilkan perspektif yang berbeda terhadap kemampuan model (Sokolova & Lapalme, 2009). Sedangkan tahap

pengujian dilakukan dengan menguji model menggunakan data aktual dalam beberapa kali percobaan.

2.11.1 Akurasi

Akurasi adalah perbandingan jumlah *klasifikasi* benar dengan total keseluruhan data uji (Sokolova & Lapalme, 2009). Metrik ini sesuai untuk *dataset* yang seimbang, namun cenderung menyesatkan pada kasus *imbalanced data*.

$$\text{Akurasi} = \frac{TP + TN}{TP + TN + FP + FN}$$

Persamaan 2.1 Persamaan Untuk Menghitung Akurasi Model (Tasnim & Baek, 2023)

2.11.2 Presisi

Presisi mengukur proporsi data positif yang diklasifikasi benar terhadap seluruh data yang diklasifikasi positif. Nilai presisi tinggi mengindikasikan rendahnya frekuensi kesalahan sistem dalam menetapkan klasifikasi positif (Sokolova & Lapalme, 2009).

$$\text{Presisi} = \frac{TP}{TP + FP}$$

Persamaan 2.2 Persamaan Untuk Menghitung Presisi Model (Tasnim & Baek, 2023)

2.11.3 Recall

Metrik *recall* menunjukkan kemampuan sistem dalam menjaring semua data yang termasuk dalam kategori positif. Nilai *recall* tinggi berarti model jarang melewatkan data positif sebenarnya (Sokolova & Lapalme, 2009).

$$\text{Recall} = \frac{TP}{TP + FN}$$

Persamaan 2.3 Persamaan Untuk Menghitung *Recall* Model (Tasnim & Baek, 2023)

2.11.4 F1-Score

F1-Score merupakan rata-rata harmonis dari presisi dan *recall*, yang menjadi metrik krusial saat diperlukan keseimbangan performa antara *false positive* dan *false negative* (Sokolova & Lapalme, 2009).

$$F_{1\text{-Score}} = 2 \times \frac{\text{Presisi} \times \text{Recall}}{\text{Presisi} + \text{Recall}}$$

Persamaan 2.4 Persamaan Untuk Menghitung *F1-Score* Model (Tasnim & Baek, 2023)

2.11.5 Confusion Matrix

Confusion matrix adalah representasi tabular yang menunjukkan jumlah *klasifikasi* benar dan salah dari model dengan membandingkan kelas aktual dengan kelas hasil klasifikasi. Terdapat empat komponen dalam matriks ini: *True Positive* (TP), *True Negative* (TN), *False Positive* (FP), dan *False Negative* (FN) (Fawcett, 2006). Dengan *confusion matrix*, peneliti dapat menganalisis kesalahan model secara lebih detail (Tharwat, 2018). Format *Confusion Matrix* dapat dilihat pada Tabel 2.1.

Tabel 2.1 *Confusion Matrix*

		<i>Prediction Class</i>	
		<i>True</i>	<i>False</i>
<i>Actual Class</i>	<i>True</i>	<i>TP (True Positive)</i>	<i>FN (False Negative)</i>
	<i>False</i>	<i>FP (False Positive)</i>	<i>TN (True Negative)</i>